

Université de Montréal

Préentraînement d'un modèle ELECTRA

par

Simon Théorêt

Département d'informatique et de recherche opérationnelle
Faculté des arts et des sciences

Mémoire présenté en vue de l'obtention du grade de
Maître ès sciences (M.Sc.)
en informatique,

November 23, 2024

Université de Montréal

Faculté des arts et des sciences

Ce mémoire intitulé

Préentraînement d'un modèle ELECTRA

présenté par

Simon Théorêt

a été évalué par un jury composé des personnes suivantes :

Nom du président du jury

(président-rapporteur)

Nom du directeur de recherche

(directeur de recherche)

Nom du membre de jury

(membre du jury)

Résumé

...sommaire et mots clés en français...

Abstract

...summary and keywords in english...

Table des matières

Résumé	v
Abstract	vii
Liste des tableaux	xi
Liste des figures	xiii
Liste des sigles et des abréviations	xv
Remerciements	xvii
Introduction	1
Chapitre 1. ELECTRA et contexte	3
1.1. Contraintes	3
1.2. Méthode de préentraînement ELECTRA	3
1.3. Infrastructures en place	4
Chapitre 2. Préentraînement d'un modèle initial	5
Chapitre 3. Modèle final	7
Chapitre 4. Directions futures	9
Chapitre 5. Conclusions	11
Références	13
Annexe A. Le titre	15
A.1. Section un de l'Annexe A	15
Annexe B. Les différentes parties et leur ordre d'apparition	17

Liste des tableaux

Liste des figures

Liste des sigles et des abréviations

MLM	Modélisation de langage avec masque, de l'anglais <i>Masked Language Modeling</i>
TAL	Traitement automatique du langage

Remerciements

...remerciements...

Introduction

Le domaine du traitement automatique des langues connaît une explosion fulgurante de techniques, de jeux de données et de modèles permettant de résoudre de nouveaux problèmes. Néanmoins, bon nombre de ces applications restent hors de portée des organisations désirant mettre en application des outils d'apprentissages automatique. En effet, la plupart des modèles de langues récents sont préentraînés sur des corpus majoritairement anglophones, avec des jetoniseurs spécialisés pour traiter le contenu anglophone. Ces deux facteurs limitent les modèles préentraînés disponibles ainsi que leur performance sur des tâches avec un corpus non anglophone.

Druide Inc. est une compagnie basée à Montréal dont le principal produit est Antidote, un logiciel de correction orthographique et grammaticale. Leur logiciel phare fait déjà usage de l'apprentissage profond pour leur moteur de correction en anglais, en plus d'utiliser un correcteur symbolique pour certains types d'erreurs. Le modèle utilisé en production pour la correction en anglais fait près de 2 corrections sur 3 et représente une part importante du moteur de correction. L'équipe de Druide désire mettre en place un modèle de correction similaire, mais adapté à la langue française. En particulier, ils désirent préentraîner un modèle ELECTRA de 14 millions de paramètres avec un corpus et un jetoniseur francophones.

Pour la réalisation du projet, nous disposons d'un jeu de données d'environ 40 GB de données non structuré. De plus, l'entraînement du modèle se fait localement sur une machine ayant accès à 3 NVIDIA RTX A4000, disposant chacune de 16 GB de mémoire VRAM.

Chapitre 1

ELECTRA et contexte

1.1. Contraintes

Le modèle doit être intégré dans le logiciel principal de *Druide*, *Antidote*. Or, le logiciel *Antidote* est déployé principalement sur les ordinateurs personnels des usagers. Cela implique d'importantes contraintes quant aux ressources disponibles pour l'exécution du modèle, notamment en ce qui à trait à la consommation de mémoire. De plus, le logiciel *Antidote* se doit d'être rapide, puisque attendre plusieurs minutes pour la correction d'un texte volumineux dégrade la qualité de l'expérience utilisateur. En d'autres mots, le modèle doit être rapide durant l'inférence. Finalement, le logiciel *antidote* cible deux système d'exploitation: Windows et MacOS. Le déploiement du modèle se fait à l'aide des librairies ONNX[2] et CoreML. Il est donc nécessaire que le modèle soit compatible avec les deux librairies.

Ces contraintes ont poussé l'équipe du TAL de *Druide* à sélectionner des petits modèles Transformers[3] avec encodeur contenant environ 14 millions de paramètres.

1.2. Méthode de préentraînement ELECTRA

La méthode ELECTRA[1] est une méthode inspirée de la modélisation de langage avec masque (Masked Language Modeling; MLM), mais qui se veut plus efficace et rapide que le MLM. La méthode ELECTRA consiste à entraîner deux modèles: un petit modèle, appelé le générateur, et le modèle final, appelé le discriminant. Le générateur reçoit des jetons masqués et doit prédire quel était le jeton original situé à la position du masque. Les prédictions du modèle sont échantillonnées, de façon à obtenir une nouvelle séquence, potentiellement différente de la séquence originale. Le discriminant reçoit la nouvelle séquence et à pour tâche de prédire quels jetons sont corrompus et lesquels n'ont pas été modifiés par le générateur. Seul le discriminant est réutilisé pour l'affinage.

Trois éléments rendent l’entraînement du discriminant plus facile. Premièrement, le générateur dispose de significativement moins de capacité que le discriminant. En effet, ce dernier contient en général 3 à 4 fois plus de paramètres (en excluant les couches de projections *embeddings*) que le générateur. De plus, les entrées du discriminant sont échantillonnées depuis la distribution engendrée par le générateur, au lieu de sélectionner les entrées les plus probables selon la distribution du générateur. Finalement, les poids du générateur sont initialisés aléatoirement et ce dernier est entraîné en même temps que le discriminant, rendant la tâche de plus en plus difficile au fur et à mesure que le générateur s’entraîne. Ces trois facteurs rendent la tâche du discriminant plus facile et permettent de générer des erreurs similaire à ce que le modèle rencontrera en production.

1.3. Infrastructures en place

Notre tâche principale consistait à préentraîner un modèle ELECTRA. Or, un modèle ELECTRA est déjà utilisé dans la tâche de correction en anglais. En effet, la librairie Transformers[4] permet un usage libre de différents modèles ELECTRA préentraînés. Le modèle utilisé dans le moteur de correction anglais est un modèle ELECTRA provenant de la librairie Transformers, qui a été affiné sur un corpus contenant des erreurs ainsi que des annotations contenant le type d’erreur. Il existe des modèles ELECTRA préentraînés sur des corpus francophone. Néanmoins, aucun d’entre eux ne respectent nos contraintes de tailles et de vitesse.

Ces annotations proviennent d’annotateurs employés par Druide. Le corpus annoté regroupe près de 100000 annotations et est utilisé pour la tâche d’affinage.

La méthode ELECTRA a été choisie pour deux raisons: c’est une tâche de préentraînement similaire à la correction d’erreurs dans un texte et blabla

Chapitre 2

Préentraînement d'un modèle initial

Chapitre 3

Modèle final

Chapitre 4

Directions futures

Chapitre 5

Conclusions

Références

- [1] Kevin Clark, Minh-Thang Luong, Quoc V. Le, et Christopher D. Manning, *Electra: Pre-training text encoders as discriminators rather than generators*, 2020.
- [2] ONNX Runtime developers, *Onnx runtime*, <https://onnxruntime.ai/>, 2021, Version: x.y.z.
- [3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, et Illia Polosukhin, *Attention is all you need*, 2023.
- [4] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, et Alexander M. Rush, *Transformers: State-of-the-art natural language processing*, Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (Online), Association for Computational Linguistics, October 2020, pp. 38–45.

Annexe A

Le titre

A.1. Section un de l'Annexe A

...texte...

Annexe B

Les différentes parties et leur ordre d'apparition

J'ajoute ici les différentes parties d'un mémoire ou d'une thèse ainsi que leur ordre d'apparition tel que décrit dans le guide de présentation des mémoires et des thèses de la Faculté des études supérieures. Pour plus d'information, consultez le guide sur le site web de la faculté (www.fes.umontreal.ca).

Ordre des éléments constitutifs du mémoire ou de la thèse		
1.	La page de titre	obligatoire
2.	La page d'identification des membres du jury	obligatoire
3.	Le résumé en français et les mots clés français	obligatoires
4.	Le résumé en anglais et les mots clés anglais	obligatoires
5.	Le résumé dans une autre langue que l'anglais ou le français (si le document est écrit dans une autre langue que l'anglais ou le français)	obligatoire
6.	Le résumé de vulgarisation	facultatif
7.	La table des matières, la liste des tableaux, la liste des figures ou autre	obligatoires
8.	La liste des sigles et des abréviations	obligatoire
9.	La dédicace	facultative
10.	Les remerciements	facultatifs
11.	L'avant-propos	facultatif
12.	Le corps de l'ouvrage	obligatoire
13.	Les index	facultatif
14.	Les références bibliographiques	obligatoires
15.	Les annexes	facultatifs
16.	Les documents spéciaux	facultatifs